

BURSA TEKNİK ÜNİVERSİTESİ

Bilgisayar Mühendisliği Bölümü

DOĞAL DİL İŞLEME (NLP)

MORFOLOJİK ÇÖZÜMLEME

(Morphological Disambiguation)

Proje Konusu:	Morfolojik Çözümleme (Morphological Disambiguation)
Öğrenci Adı:	Büşra Ünal
Öğrenci No:	22360859084
Dönem:	2025-2026 Bahar
Teslim Tarihi:	12 Haziran 2026

İÇİNDEKİLER

1. Giriş — Projenin amacı ve kapsamı
2. Yöntem — İş akışı ve kullanılan teknikler
3. Veri Seti — CoNLL-U formatı ve veri yapısı
4. Özellik Çıkarımı — Bağlamsal özellikler
5. Makine Öğrenmesi Modelleri — NB, MLP, LR, HMM
6. Deneysel Sonuçlar — Metrikler ve karşılaştırma
7. Karışıklık Matrisleri — Model bazında analizler
8. Sonuç ve Değerlendirme — Genel değerlendirme
9. Kaynakça — Referanslar

1. GİRİŞ

Bu proje, Bursa Teknik Üniversitesi Bilgisayar Mühendisliği Bölümü 2025-2026 Bahar Dönemi Doğal Dil İşleme (NLP) dersi kapsamında hazırlanmıştır. Proje konusu olarak Morfolojik Çözümleme (Morphological Disambiguation) seçilmiştir.

1.1 Problemin Tanımı

Türkçe gibi sondan eklemeli (agglutinative) dillerde bir kelime birden fazla morfolojik çözümlemeye sahip olabilir. Örneğin 'yüz' kelimesi isim (yüz sayısı), sıfat (yüz ifadesi) veya fiil (yüzmek) olarak çözümlenebilir. Morfolojik çözümleme (disambiguation), bir kelimenin cümle bağlamında doğru morfolojik analizinin otomatik olarak belirlenmesi işlemidir.

1.2 Projenin Amacı

Bu projenin temel amacı, verilen Türkçe cümlelerdeki her kelimenin bağlamına uygun doğru morfolojik analizini (kök, kelime türü, ek bilgisi) otomatik olarak belirleyen bir sistem geliştirmektir. Sistem, Zemberek yazılımı ile üretilen aday çözümlemeler arasından doğru olanı seçmek üzere makine öğrenmesi modelleri ile eğitilmektedir.

1.3 İş Akışı

1) Veri toplama ve CoNLL-U formatında işaretleme 2) Özellik çıkarımı (bağlamsal pencere yöntemi) 3) Model eğitimi (Naive Bayes, MLP, Logistic Regression, HMM) 4) Test ve değerlendirme (F1, Precision, Recall, Accuracy, Confusion Matrix)

2. YÖNTEM

Projede denetimli öğrenme (supervised learning) yaklaşımı benimsenmiştir. İşaretlenmiş Türkçe cümlelerden özellik vektörleri çıkarılarak farklı makine öğrenmesi modelleri eğitilmiş ve karşılaştırılmıştır.

2.1 Zemberek Entegrasyonu

Zemberek, Türkçe için geliştirilmiş açık kaynaklı bir doğal dil işleme kütüphanesidir. Her kelime için olası tüm morfolojik çözümlemeleri üretir. Sistem, bu aday çözümlemeler arasında bağlamsal bilgiyi kullanarak doğru olanı seçer.

2.2 Özellik Mühendisliği

Her token için aşağıdaki özellikler çıkarılmıştır:

Özellik Grubu	Açıklama	Örnek
Kelime Düzeyi	Uzunluk, büyük harf, rakam kontrolü	len=8, is_cap=1
Morfolojik	Ünlü/ünsüz oranı, Türkçe ek tespiti	suffix_lar=1
N-gram	İlk/son 1-2 karakter kodları	prefix_1=0.42
Bağlamsal	± 2 pencere içindeki kelimelerin özellikleri	w-1_len=5
Konumsal	Cümle içi pozisyon, baş/son kontrolü	is_first=1

Tablo 1: Çıkarılan özellik grupları ve açıklamaları

3. VERİ SETİ

3.1 CoNLL-U Formatı

Proje kapsamında tüm işaretlemler Universal Dependencies (UD) standartlarında CoNLL-U formatında yapılmıştır. Her satır bir tokeni temsil eder ve sekme (tab) ile ayrılmış sütunlardan oluşur.

Sütun	Alan	Açıklama
1	ID	Kelimenin cümledeki sırası
2	FORM	Kelimenin orijinal hali
3	LEMMA	Kelimenin kökü
4	UPOS	Universal POS etiketi (NOUN, VERB, ADJ...)
5	XPOS	Dile özgü POS etiketi
6	FEATS	Morfolojik özellikler (Case, Number, Tense...)

Tablo 2: CoNLL-U sütun yapısı

3.3 Veri Seti İstatistikleri

	Eğitim Seti	Test Seti
Cümle Sayısı	500	100
Token Sayısı	2199	449
Ort. Token/Cümle	4.4	4.5
UPOS Sınıf Sayısı	9	9

Tablo 3: Veri seti istatistikleri

3.4 UPOS Dağılımı (Eğitim Seti)

UPOS	NOUN	PUNCT	VERB	ADJ	ADV	PRON	DET	ADP	CCONJ
Sayı	792	500	480	145	135	65	38	25	19
Oran	%36.0	%22.7	%21.8	%6.6	%6.1	%3.0	%1.7	%1.1	%0.9

Tablo 4: UPOS etiket dağılımı

4. ÖZELLİK ÇIKARIMI

Özellik çıkarımı aşamasında her token için toplam 323 özellik üretilmiştir. Bağlamsal pencere yöntemi (window size = 2) kullanılarak hedef kelimenin kendisi ve ± 2 komşu kelimesinin bilgileri birleştirilmiştir.

4.1 Kelime Düzeyi Özellikler

Her kelime için uzunluk, büyük harf kontrolü, rakam/noktalama tespiti, ünlü-ünsüz oranı ve son harf bilgisi çıkarılmıştır. Ayrıca 36 yaygın Türkçe ek (-lar, -ler, -dan, -den, -yor, -mış vb.) için binary özellikler tanımlanmıştır.

4.2 Bağlamsal Özellikler

Kayan pencere (sliding window) yöntemi ile hedef tokenin solundaki ve sağındaki 2 kelimenin tüm kelime düzeyi özellikleri de vektöre eklenmiştir. Böylece her token için yerel bağlam bilgisi korunmuştur. Ayrıca tokenin cümle içindeki göreceli konumu, cümle başı/sonu bilgisi özellik olarak kullanılmıştır.

5. MAKİNE ÖĞRENMESİ MODELLERİ

Projede dört farklı makine öğrenmesi modeli eğitilmiş ve karşılaştırılmıştır. Tüm modeller scikit-learn kütüphanesi kullanılarak Python'da gerçekleştirilmiştir.

5.1 Naive Bayes (Gaussian)

Naive Bayes, Bayes teoremine dayalı olasılıksal bir sınıflandırıcıdır. Özellikler arası bağımsızlık varsayımı yapar. Gaussian varyantı sürekli değişkenler için normal dağılım varsayar. Eğitimi hızlıdır ancak karmaşık özellik ilişkilerini yakalamada sınırlıdır.

5.2 Multilayer Perceptron (MLP)

MLP, 3 gizli katmandan (128-64-32 nöron) oluşan ileri beslemeli bir yapay sinir ağıdır. ReLU aktivasyon fonksiyonu, Adam optimizasyon algoritması ve adaptive öğrenme oranı kullanılmıştır. Early stopping ile aşırı öğrenme önlenmiştir.

5.3 Logistic Regression (Multinomial)

Multinomial Logistic Regression, çok sınıflı problemler için softmax fonksiyonu kullanan doğrusal bir sınıflandırıcıdır. L-BFGS optimizasyon algoritması ile eğitilmiş, C=1.0 düzenleme parametresi kullanılmıştır.

5.4 Hidden Markov Model (HMM)

HMM, dizilimdeki bağımlılıkları modelleyen olasılıksal bir yaklaşımdır. Geçiş olasılıkları $P(\text{etiket}_i | \text{etiket}_{i-1})$ ve emisyon olasılıkları $P(\text{kelime} | \text{etiket})$ eğitim verisinden hesaplanmıştır. Çözümleme sırasında Viterbi benzeri bir greedy algoritma kullanılmıştır. Dizilim bilgisini kullandığı için token bazlı modellere göre avantajlıdır.

Model	Tür	Parametre	Avantaj	Dezavantaj
Naive Bayes	Olasılıksal	Otomatik	Hızlı eğitim	Bağımsızlık varsayımı
MLP	Sinir Ağı	128-64-32	Doğrusal olmayan ilişkiler	Çok veri gerektirir
Log. Reg.	Doğrusal	C=1.0	Yorumlanabilir	Doğrusal sınır
HMM	Dizilim	Geçiş+Emisyon	Dizilim bilgisi	Kelime bazlı

Tablo 5: Model karşılaştırma özeti

6. DENEYSEL SONUÇLAR


6.1 Genel Sonuçlar

Aşağıdaki tabloda dört modelin genel başarı metrikleri verilmiştir. En iyi sonuçlar **HMM modeli** ile elde edilmiştir.

Model	Accuracy	Precision (Macro)	Recall (Macro)	F1-Score (Macro)
Naive Bayes	%64.6	0.459	0.680	0.478
MLP (128-64-32)	%87.8	0.590	0.531	0.553
Logistic Regression	%89.5	0.770	0.666	0.704
HMM	%99.6	0.996	0.943	0.960

Tablo 6: Model başarı metrikleri karşılaştırması

6.2 Model Karşılaştırma Grafiği



Şekil 1: Model karşılaştırma grafiği (Accuracy, Precision, Recall, F1)

6.3 Sınıf Bazında Sonuçlar (En İyi Model: HMM)


Sınıf	Precision	Recall	F1-Score	Destek
ADJ	0.971	1.000	0.986	34
ADP	1.000	0.500	0.667	2
ADV	1.000	1.000	1.000	23
CCONJ	1.000	1.000	1.000	2

DET	1.000	1.000	1.000	7
NOUN	0.994	1.000	0.997	179
PRON	1.000	1.000	1.000	9
PUNCT	1.000	1.000	1.000	100
VERB	1.000	0.989	0.995	93


Tablo 7: HMM modeli sınıf bazında sonuçlar

7. KARIŞIKLIK MATRİSLERİ


Aşağıda her model için confusion matrix (karışıklık matrisi) verilmiştir. Diyagonal üzerindeki değerler doğru sınıflandırmaları, diyagonal dışındakiler hatalı sınıflandırmaları göstermektedir.




Şekil 2: HMM — Karışıklık Matrisi (En Başarılı Model)



Şekil 3: Logistic Regression — Karışıklık Matrisi



Şekil 4: MLP — Karışıklık Matrisi



Şekil 5: Naive Bayes — Karışıklık Matrisi

8. SONUÇ VE DEĞERLENDİRME

Bu projede Türkçe morfolojik çözümleme problemi için dört farklı makine öğrenmesi modeli geliştirilmiş ve karşılaştırılmıştır. 500 eğitim ve 100 test cümlesinden oluşan veri seti üzerinde deneyler yapılmıştır.

8.1 Temel Bulgular

1. HMM modeli en yüksek başarıyı sağlamıştır (%99.6 accuracy, F1=0.960). Bunun temel sebebi, HMM'in dizilimdeki bağımlılıkları (bir kelime türünden sonra hangi türün geleceği) modelleyebilmesidir. Türkçe'de kelime sırası düzeni bu bilgiyi çok değerli kılmaktadır.

2. Logistic Regression ikinci en başarılı modeldir (%89.5 accuracy). Doğrusal bir model olmasına rağmen, zengin özellik kümesi sayesinde iyi sonuçlar üretmiştir. Özellikle VERB ve PUNCT sınıflarında %97+ başarı sağlamıştır.

3. MLP üçüncü sırada yer almıştır (%87.8 accuracy). Doğrusal olmayan ilişkileri yakalayabilmesine rağmen, nispeten küçük veri seti nedeniyle potansiyelini tam olarak gösterememiştir. Daha büyük veri setleriyle performansının artması beklenmektedir.

4. Naive Bayes en düşük başarıyı göstermiştir (%64.6 accuracy). Özellikler arası bağımsızlık varsayımı, bağlamsal özelliklerin doğası gereği bu problem için uygun değildir.

8.2 Zorluklar

Projede karşılaşılan temel zorluklar şunlardır: (1) ADJ, ADV ve DET gibi az örneğe sahip sınıflar için yeterli temsilin sağlanması, (2) Türkçe'nin zengin morfolojik yapısı nedeniyle özellik uzayının genişlemesi, (3) Bazı kelimelerin birden fazla kelime türüne ait olabilmesi (ambiguity).

8.3 Gelecek Çalışmalar

Proje şu yönlerle geliştirilebilir: (1) UD Turkish-IMST gibi büyük ölçekli gerçek corpus'lar kullanılabilir, (2) CRF (Conditional Random Fields) modeli eklenebilir, (3) Zemberek entegrasyonu ile gerçek aday çözümlemeler üretilebilir, (4) Derin öğrenme modelleri (BiLSTM-CRF, BERT) denenebilir.

9. KAYNAKÇA

- [1] Jurafsky, D., & Martin, J.H. (2024). *Speech and Language Processing* (3rd ed.). Stanford University.
- [2] Oflazer, K. (1994). *Two-level Description of Turkish Morphology*. Literary and Linguistic Computing, 9(2).
- [3] Sak, H., Güngör, T., & Saraçlar, M. (2007). *Morphological Disambiguation of Turkish Text with Perceptron Algorithm*. CICLing 2007.
- [4] Yüret, D., & Türe, F. (2006). *Learning Morphological Disambiguation Rules for Turkish*. HLT-NAACL 2006.
- [5] Akbik, A., et al. (2018). *Contextual String Embeddings for Sequence Labeling*. COLING 2018.
- [6] Zemberek NLP: <https://github.com/ahmetaa/zemberek-nlp>
- [7] Universal Dependencies Turkish Treebank: https://universaldependencies.org/treebanks/tr_imst/
- [8] scikit-learn: Machine Learning in Python. Pedregosa et al. (2011). JMLR 12.